

LAPORAN PROJECT PEMBELAJARAN MESIN DASAR
SEMESTER GENAP 2025/2026

IDENTITAS PROYEK	
Judul	Perbandingan Support Vector Machine dan Random Forest, pada Klasifikasi Kelainan Jantung Sinyal Phonocardiogram Menggunakan Fitur DWT, MFCC, dan Entropy-Based
Topik	Biomedis
Identitas Penyusun	1. Aisyah Imani Khoirunnisa (24031554020) 2. Aryanti Indah Lestari (24031554196)
Kelas	2024D

1. PENDAHULUAN

1.1. Latar Belakang

Salah satu penyakit yang paling mematikan dan menjadi perhatian utama di dunia adalah penyakit jantung. Penyakit ini dapat dikenali melalui perubahan detak jantung yang tidak normal. Perubahan detak jantung tersebut dapat menjadi indikator penting kondisi pasien, terutama bagi mereka yang memiliki riwayat penyakit jantung (Cicilya, 2024). Dalam praktik medis *modern*, deteksi kondisi jantung dapat dilakukan melalui sinyal *phonocardiogram* (PCG), yaitu sinyal suara jantung yang merepresentasikan aktivitas mekanik jantung. Namun, sinyal PCG memiliki karakteristik yang kompleks, bersifat *non-stasioner*, serta rentan terhadap noise, sehingga diperlukan metode komputasi yang mampu mengekstraksi informasi secara optimal.

Salah satu metode yang banyak digunakan adalah *Discrete Wavelet Transform* (DWT) karena mampu merepresentasikan sinyal dalam domain waktu dan frekuensi simultan. Penelitian oleh Touluni dkk., (2023) menunjukkan bahwa kombinasi DWT dan *Support Vector Machine* (SVM) efektif dalam klasifikasi sinyal medis karena mampu meningkatkan representasi fitur sinyal yang kompleks. Selain DWT, *Mel-Frequency Cepstral Coefficients* (MFCC) merupakan metode ekstraksi fitur yang banyak digunakan pada analisis sinyal audio karena mampu menangkap karakteristik spektral yang sesuai dengan persepsi pendengaran manusia. Pada sinyal PCG, MFCC dapat merepresentasikan pola suara jantung normal maupun abnormal yang sulit diamati secara langsung pada domain waktu. Penelitian Chasmi dkk. (2019) menunjukkan bahwa kombinasi DWT dan MFCC mampu menghasilkan representasi fitur yang lebih informatif sehingga meningkatkan performa proses klasifikasi sinyal medis. Karakteristik sinyal jantung yang kompleks juga dapat direpresentasikan melalui fitur berbasis *entropy-based*. *Entropy-Based* digunakan untuk mengukur tingkat kompleksitas, ketidakteraturan, dan distribusi energi pada sinyal. Fitur *entropy-based* telah banyak digunakan pada klasifikasi sinyal biomedis. Oleh karena itu, kombinasi DWT, MFCC, dan *Entropy-Based Feature* diharapkan dapat

menghasilkan representasi fitur yang lebih komprehensif dalam menggambarkan kondisi sinyal PCG.

Pada tahapan klasifikasi pada penelitian ini dilakukan menggunakan *Support Vector Machine* (SVM) dan *Random Forest*. *Support Vector Machine* (SVM) merupakan salah satu metode klasifikasi dalam data *mining* yang digunakan untuk memprediksi kelas suatu data, serta dapat diterapkan pada masalah klasifikasi maupun regresi. SVM bekerja dengan mencari *hyperplane* terbaik sebagai batas pemisah antar kelas data dengan memaksimalkan margin atau jarak antar kelas (Utari, 2023). SVM merupakan metode klasifikasi yang memiliki performa tinggi dalam menangani data berdimensi besar dan telah banyak digunakan dalam klasifikasi sinyal medis seperti ECG dan PCG. Studi oleh Li dkk., (2019) menunjukkan bahwa SVM memiliki kemampuan generalisasi yang baik dalam membedakan kelas normal dan abnormal. Selain SVM, *Random Forest* merupakan algoritma *ensemble learning* yang membangun banyak pohon keputusan dan menggabungkan hasil prediksinya untuk meningkatkan akurasi serta mengurangi risiko *overfitting*. Pada penelitian Shakhovska & Zagorodniy. (2024) menunjukkan bahwa Random Forest mampu memberikan performa yang kompetitif dalam klasifikasi suara jantung.

Permasalahan umum pada dataset medis adalah ketidakseimbangan kelas. Hal ini dapat menyebabkan model bias terhadap kelas mayoritas dan menurunkan kemampuan deteksi kelas minoritas. Salah satu pendekatan yang banyak digunakan untuk mengatasi masalah tersebut adalah data *augmentation*. Pada sinyal audio seperti PCG, data *augmentation* dapat dilakukan dengan memodifikasi sinyal tanpa mengubah informasi utama yang terkandung di dalamnya. Pada penelitian Shakhovska & Zagorodniy. (2024) menunjukkan bahwa augmentasi data dapat meningkatkan keragaman data pelatihan.

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan metode klasifikasi kelainan jantung pada sinyal PCG menggunakan kombinasi *Discrete Wavelet Transform* (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan *Entropy Based Feature* sebagai metode ekstraksi fitur. Selanjutnya dilakukan perbandingan performa algoritma *Support Vector Machine* (SVM) dan *Random Forest*. Evaluasi dilakukan menggunakan *matrix accuracy*, *precision*, *recall*, dan *f1-score*.

1.2. Rumusan Masalah dan Tujuan

Penelitian ini berfokus pada klasifikasi kelainan jantung menggunakan sinyal *Phonocardiogram* (PCG) yang memiliki karakteristik kompleks, non-stasioner, dan rentan terhadap noise. Selain itu, ketidakseimbangan kelas pada dataset dapat memengaruhi kemampuan model dalam mengenali seluruh kategori data secara optimal. Oleh karena itu, rumusan masalah dalam penelitian ini adalah bagaimana menerapkan data augmentation untuk menangani ketidakseimbangan kelas pada sinyal PCG, bagaimana menggabungkan metode *Discrete Wavelet Transform* (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan *Entropy-Based Feature* untuk menghasilkan representasi fitur yang mampu membedakan kondisi jantung normal dan abnormal, serta bagaimana membandingkan performa algoritma *Support Vector*

Machine (SVM) dan Random Forest dalam mengklasifikasikan sinyal PCG berdasarkan nilai accuracy, precision, recall, dan f1-score.

Sehingga tujuan dari penelitian ini adalah menerapkan data augmentation pada data training untuk mengatasi ketidakseimbangan kelas pada dataset sinyal *Phonocardiogram* (PCG), mengekstraksi fitur sinyal menggunakan kombinasi *Discrete Wavelet Transform* (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan Entropy-Based Feature guna memperoleh representasi karakteristik sinyal yang lebih informatif, serta membandingkan performa algoritma *Support Vector Machine* (SVM) dan *Random Forest* dalam klasifikasi kondisi jantung normal dan abnormal berdasarkan metrik accuracy, precision, recall, dan f1-score.

1.3. Pendekatan Pemecahan Masalah

Pendekatan pemecahan masalah pada penelitian ini diawali dengan pengumpulan data sinyal *Phonocardiogram* (PCG) yang kemudian dibagi menjadi data *training* dan data *testing* dengan rasio 70:30. Selanjutnya dilakukan *preprocessing* berupa resampling, normalisasi, *denoising*, dan penyesuaian panjang sinyal. Untuk mengatasi ketidakseimbangan kelas pada data training, diterapkan teknik data augmentation melalui amplitudo *scaling*, penambahan noise ringan, dan time shifting sehingga distribusi data menjadi lebih seimbang tanpa mengubah informasi utama sinyal jantung.

Tahap berikutnya adalah ekstraksi fitur menggunakan kombinasi *Discrete Wavelet Transform* (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan Entropy-Based Feature untuk memperoleh representasi karakteristik sinyal yang lebih informatif. Fitur yang dihasilkan kemudian digunakan sebagai masukan algoritma *Support Vector Machine* (SVM) dan *Random Forest* untuk mengklasifikasikan sinyal PCG normal dan abnormal. Performa kedua model dievaluasi menggunakan *confusion matrix*, accuracy, precision, recall, f1-score guna menentukan metode klasifikasi yang memberikan hasil terbaik.


2. Metodologi

2.1. Eksplorasi Dataset

Dataset yang digunakan dalam penelitian ini berasal dari *PhysioNet Challenge* 2016 ([Link Dataset](#)) yang berisi rekaman suara jantung atau *Phonocardiogram* (PCG) dalam format wav. Dataset terdiri dari beberapa folder *training* yaitu *training-a*, *training-b*, *training-c*, *training-d*, *training-e*, dan *training-f*, yang digunakan untuk proses pelatihan serta pengujian model. Setiap data memiliki label normal (1) dan abnormal (-1) yang tersimpan pada file *REFERENCE.csv*. Jenis data yang digunakan berupa sinyal audio PCG yang merepresentasikan aktivitas mekanik jantung. Dataset memiliki karakteristik berupa perbedaan amplitudo, durasi sinyal, dan pola sinyal. Pada penelitian ini, seluruh data dari folder *training* digabungkan kemudian dibagi menjadi data *training* dan data *testing* dengan rasio 70:30. Pada tahap eksplorasi dataset dilakukan analisis struktur data, distribusi kelas, jenis label, dan karakteristik sinyal PCG. Data kemudian diproses melalui data *augmentation*, ekstraksi fitur

menggunakan kombinasi *Discrete Wavelet Transform* (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan *Entropy-Based Feature*, serta klasifikasi menggunakan algoritma SVM dan *Random Forest*.

2.2. Tahapan Penelitian



Gambar 1. Diagram Alur Pengerjaan

Pada gambar 1 menjelaskan proses klasifikasi data menggunakan metode DWT dan SVM. Proses dimulai dari pengumpulan dataset, kemudian dilakukan *preprocessing* untuk membersihkan dan menyiapkan data. Setelah itu, dilakukan analisis data eksploratif untuk memahami karakteristik data. Hasil EDA menunjukkan adanya ketidakseimbangan data pada data train sehingga dilakukan augmentasi pada

kelas minoritas untuk meningkatkan jumlah dan variasi data. Setelah itu, dilakukan ekstraksi fitur menggunakan DWT untuk memperoleh waktu dan frekuensi, MFCC untuk menangkap karakteristik spektral suara jantung, serta *Entropy-Based Features* untuk merepresentasikan tingkat kompleksitas sinyal. Seluruh fitur kemudian digabungkan melalui proses *feature fusion* sehingga menghasilkan representasi data yang lebih komprehensif, lalu dilakukan scaling.. Fitur hasil penggabungan selanjutnya digunakan sebagai masukan bagi algoritma SVM dan *Random Forest* untuk membandingkan performa klasifikasi kelainan jantung. Kinerja kedua model dievaluasi menggunakan *matrix accuracy*, *precision*, *recall*, dan *f1-score*.

2.2.1. Mel-Frequency Cepstral Coefficients

Mel-Frequency Cepstral Coefficients (MFCC) adalah fitur audio yang umum digunakan dalam pengenalan suara, karena kemampuannya dalam menggambarkan variasi sinyal dalam frekuensi rendah (Aurelius dkk., 2024). MFCC bekerja dengan meniru cara sistem pendengaran manusia dalam menangkap dan memproses frekuensi suara melalui skala Mel, yaitu skala frekuensi yang dirancang sesuai dengan persepsi pendengaran manusia. Proses ekstraksi MFCC diawali dengan pembagian sinyal ke dalam beberapa frame, dilanjutkan dengan transformasi ke domain frekuensi menggunakan *Fast Fourier Transform* (FFT), kemudian dilakukan pemetaan energi spektrum ke dalam Mel Filter Bank. Selanjutnya, nilai logaritmik dari energi filter dihitung dan ditransformasikan menggunakan *Discrete Cosine Transform* (DCT) untuk menghasilkan koefisien MFCC. Koefisien yang diperoleh mampu merepresentasikan informasi penting karakteristik spektral sinyal. Pada sinyal PCD, MFCC dapat digunakan untuk menangkap karakteristik suara jantung normal maupun abnormal yang sulit diamati langsung oleh domain waktu (Malik dkk. 2023)

2.2.2. Entropy Based

Metode pemilihan fitur *Entropy-Based* yang cepat dan efektif digunakan sebagai teknik pengurangan dimensi. Entropi digunakan untuk mengukur informasi rata-rata suatu fitur, sehingga fitur yang mengandung lebih banyak informasi memiliki entropi yang lebih tinggi. Oleh karena itu, kriteria entropi dapat digunakan untuk memilih fitur yang paling relevan dan mengurangi fitur yang bersifat redundan maupun kurang informatif. Dalam teori informasi, entropi mengukur tingkat ketidakpastian atau jumlah informasi rata-rata yang terkandung dalam suatu variabel acak. Salah satu ukuran yang paling umum digunakan adalah *Shannon Entropy* (Chashmi dkk., 2019). Pada pemrosesan sinyal biomedis, seperti sinyal EKG maupun PCG, fitur berbasis entropi digunakan untuk merepresentasikan tingkat kompleksitas, ketidakteraturan, dan distribusi informasi pada sinyal. Oleh karena itu, fitur dengan nilai entropi yang tinggi dapat dimanfaatkan untuk meningkatkan kemampuan model dalam membedakan kondisi normal dan abnormal pada proses klasifikasi (Chashmi dkk., 2019).

2.2.3. Discrete Wavelet Transform (DWT)

Discrete Wavelet Transform (DWT) merupakan metode transformasi sinyal yang digunakan untuk menganalisis sinyal pada domain waktu dan frekuensi secara bersamaan. DWT bekerja dengan memecah sinyal menjadi beberapa komponen frekuensi rendah dan frekuensi tinggi melalui proses dekomposisi menggunakan fungsi *wavelet*. Transformasi *wavelet* adalah teknik estimasi spektral yang dapat merepresentasikan suatu fungsi atau sinyal sebagai deret *wavelet* tak hingga. Proses ini dilakukan dengan menggeser dan mengubah skala *mother wavelet* sehingga menghasilkan kombinasi fungsi *wavelet* tertentu. Hasil dekomposisi sinyal akan menghasilkan sekumpulan koefisien yang disebut koefisien *wavelet*. Koefisien *wavelet* tersebut menyimpan informasi penting dari sinyal asli sehingga sinyal awal dapat direkonstruksi kembali menggunakan kombinasi fungsi *wavelet* dan koefisien yang diperoleh (Alegh dkk., 2021).

2.2.4. Support Vector Machine (SVM)

Algoritma *Support Vector Machine* adalah algoritma yang bertujuan untuk menemukan *hyperplane* maksimal, *hyperplane* adalah suatu fungsi yang dapat memisahkan antara dua kelas (Abdusyukur, 2023). SVM memetakan vektor input ke dalam ruang fitur dengan dimensi yang lebih tinggi dan mengidentifikasi *hyperplane* yang memisahkan titik data menjadi dua kelas (Rismawati dkk., 2024). Metode SVM banyak digunakan dalam klasifikasi sinyal medis karena memiliki kemampuan yang baik dalam menangani data berdimensi tinggi dan pola data yang kompleks. SVM juga dapat melakukan pelatihan dengan cepat dan mampu mengatasi tantangan dalam menghadapi data yang ambigu (Wulandari dkk., 2025). Oleh karena itu, metode SVM dipilih dalam penelitian ini karena kemampuannya mengelola ketidakseimbangan kelas dan membangun batas keputusan yang optimal untuk klasifikasi Kelainan Jantung pada Sinyal *Phonocardiogram*.

2.2.5. Random Forest

Random Forest merupakan algoritma *ensemble learning* yang membangun banyak pohon keputusan dan menggabungkan hasil prediksinya untuk meningkatkan akurasi serta mengurangi risiko *overfitting*. Metode ini menggunakan teknik *bagging* (bootstrap aggregating), yaitu proses pembentukan beberapa model pohon keputusan menggunakan sampel data yang dipilih secara acak dari data pelatihan. selain itu, pada setiap proses pembentukan node, *Random Forest* hanya menggunakan sebagian fitur yang dipilih secara acak sehingga mampu mengurangi korelasi antar pohon dan meningkatkan kemampuan generalize model. Hasil klasifikasi ditentukan berdasarkan *majority voting* dari seluruh pohon yang terbentuk. Pada klasifikasi suara jantung, *Random Forest* telah menunjukkan kemampuan yang kompetitif dalam membedakan kondisi jantung normal dan abnormal berdasarkan fitur hasil ekstraksi sinyal audio (Shakhovska & Zagorodniy, 2024).

2.3. Preprocessing


Tahap *preprocessing* dilakukan untuk membersihkan dan menyeragamkan sinyal PCG sebelum digunakan pada proses ekstraksi fitur dan klasifikasi. Pada penelitian ini, *preprocessing* terdiri dari beberapa tahap yaitu *resampling*, normalisasi, *denoising*, serta *padding* dan *truncating*.

Pertama, seluruh data audio dimuat menggunakan fungsi *librosa.load()* dengan *sampling rate* sebesar 2000 Hz. Proses ini bertujuan untuk menyeragamkan frekuensi *sampling* setiap sinyal sehingga seluruh data memiliki representasi yang konsisten dan dapat mengurangi kompleksitas komputasi. Selanjutnya, dilakukan proses normalisasi dengan membagi amplitudo sinyal terhadap nilai amplitudo maksimum. Normalisasi bertujuan untuk menyamakan rentang amplitudo antar sinyal sehingga perbedaan volume rekaman tidak mempengaruhi proses klasifikasi.

Tahap berikutnya adalah *denoising* dengan menghilangkan amplitudo sinyal yang memiliki nilai absolut kurang dari 0,01. Proses ini dilakukan untuk mengurangi *noise* kecil pada sinyal PCG sehingga karakteristik utama sinyal lebih terlihat. Setelah itu, dilakukan proses *padding* dan *truncating* agar seluruh sinyal memiliki panjang yang sama yaitu 10.000 sampel. Jika panjang sinyal kurang dari 10.000 maka dilakukan penambahan nol (*padding*), sedangkan jika panjang sinyal melebihi 10.000 maka sinyal dipotong (*truncating*). Proses ini dilakukan agar seluruh data memiliki ukuran yang seragam sebelum masuk ke tahap ekstraksi fitur dan klasifikasi menggunakan SVM. Semua tahapan *preprocessing* tersebut diterapkan pada data *training* dan data *validation* sehingga seluruh dataset memiliki format yang konsisten untuk proses analisis selanjutnya.


2.4. Exploratory Data Analysis

Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik awal dataset sinyal *Phonocardiogram* (PCG) setelah proses *preprocessing*. Pada tahap ini dilakukan analisis terhadap distribusi label, visualisasi *waveform* sinyal, perbandingan sinyal normal dan abnormal, serta visualisasi *spectrogram* untuk melihat pola frekuensi pada sinyal suara jantung. Tahap EDA membantu dalam memahami kondisi data sebagai dasar proses penanganan ketidakseimbangan kelas, ekstraksi fitur menggunakan kombinasi *Discrete Wavelet Transform* (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan *Entropy-Based Feature*, serta klasifikasi menggunakan algoritma SVM dan *Random Forest*.




Gambar 2. Distribusi Label Training

Berdasarkan Gambar 1, distribusi label pada data *training* menunjukkan jumlah data abnormal lebih banyak dibandingkan data normal, sehingga dataset *training* bersifat tidak seimbang (imbalanced data). Kondisi ini dapat mempengaruhi performa model klasifikasi karena model cenderung lebih mengenali kelas mayoritas.




Gambar 3. Waveform PCG-Normal



Gambar 4. Waveform PCG-Abnormal

Gambar 3 dan Gambar 4 menunjukkan perbandingan *waveform* sinyal *Phonocardiogram* (PCG) antara kondisi normal dan abnormal. Pada sinyal normal terlihat pola gelombang yang lebih teratur dan stabil dengan puncak amplitudo yang muncul secara periodik dan konsisten, sedangkan pada sinyal abnormal terlihat fluktuasi amplitudo yang lebih bervariasi serta pola sinyal yang lebih tidak teratur. Perbedaan karakteristik sinyal tersebut menunjukkan adanya perubahan pada suara jantung yang dapat digunakan sebagai informasi penting dalam proses ekstraksi fitur menggunakan kombinasi Discrete Wavelet Transform (DWT), Mel-Frequency Cepstral

Coefficients (MFCC), dan Entropy-Based Feature, serta klasifikasi menggunakan algoritma SVM dan Random Forest.



Gambar 5. Spectrogram Sinyal PCG

Gambar 5 menunjukkan visualisasi spectrogram sinyal *Phonocardiogram* (PCG). *Spectrogram* digunakan untuk melihat distribusi frekuensi sinyal terhadap waktu berdasarkan intensitas warna. Pada gambar terlihat bahwa sebagian besar area spectrogram didominasi oleh warna gelap yang menunjukkan energi sinyal relatif rendah. Namun, energi sinyal yang paling kuat terkonsentrasi pada rentang frekuensi rendah, yaitu sekitar 0-200 Hz, yang ditunjukkan oleh warna kuning hingga oranye pada bagian bawah spectrogram. Pola ini menunjukkan bahwa komponen utama sinyal suara jantung berada pada frekuensi rendah, sedangkan energi pada frekuensi yang lebih tinggi cenderung lebih kecil.

2.5. Augmentasi

Setelah dilakukan *Exploratory Data Analysis* (EDA), diketahui bahwa distribusi kelas pada data *train* bersifat *imbalanced*, yaitu jumlah kelas normal lebih sedikit dibandingkan kelas abnormal. Oleh karena itu, dilakukan data *augmentation* pada kelas minoritas untuk menyeimbangkan jumlah data antar kelas sebelum proses ekstraksi fitur dan pelatihan model.

Augmentasi dilakukan dengan menghasilkan variasi baru dari sinyal asli tanpa mengubah karakteristik utama sinyal. Pada penelitian ini digunakan tiga teknik augmentasi, yaitu amplitude *scaling*, *Gaussian noise injection*, dan *time shifting*. Amplitude *scaling* dilakukan dengan mengalikan sinyal menggunakan faktor skala acak pada rentang 0,95-1,05 untuk mensimulasikan variasi amplitudo sinyal yang mungkin terjadi pada proses perekaman. Selanjutnya, *Gaussian noise injection* diterapkan dengan menambahkan noise acak berintensitas rendah untuk meningkatkan ketahanan model terhadap gangguan sinyal. Teknik terakhir adalah *time shifting*, yaitu menggeser posisi sinyal secara acak dalam rentang tertentu untuk mensimulasikan variasi temporal tanpa mengubah pola utama suara jantung.

Proses augmentasi hanya diterapkan pada data *train* setelah proses pembagian data (*train-test split*) untuk menghindari terjadinya data *leakage*. Augmentasi dilakukan

secara berulang pada kelas minoritas hingga jumlah sampel pada kedua kelas menjadi seimbang.

2.6. Ekstraksi Fitur

2.6.1. Discrete Wavelet Transform

Pada tahap ini, setiap sinyal PCG didekomposisi menggunakan *Discrete Wavelet Transform* (DWT) dengan *mother wavelet Daubechies 4* (db4) dan level dekomposisi sebanyak 4 level. Proses dekomposisi menghasilkan beberapa koefisien aproksimasi dan detail yang merepresentasikan informasi sinyal pada berbagai rentang frekuensi. Selanjutnya, dari setiap koefisien wavelet dihitung jumlah fitur statistik yang terdiri atas mean, standar deviasi, nilai minimum, nilai maksimum, median, persentil ke-25, persentil ke-75, dan *Root Mean Square* (RMS). Fitur-fitur tersebut digunakan untuk merepresentasikan karakteristik sinyal pada domain waktu dan frekuensi sehingga informasi penting dari sinyal PCG dapat dipertahankan dalam bentuk numerik.

2.6.2. Mel-Frequency Cepstral Coefficients

Setelah proses DWT, dilakukan ekstraksi fitur menggunakan *Mel-Frequency Cepstral Coefficients* (MFCC). Pada penelitian ini digunakan 13 koefisien MFCC ($n_{mfcc} = 13$) untuk setiap sinyal PCG. MFCC digunakan untuk menangkap karakteristik spektral suara jantung yang menyerupai mekanisme pendengaran manusia. Dari setiap koefisien dihitung nilai mean dan standar deviasi pada seluruh frame sinyal.

2.6.3. Entropy-Based Feature

Selain DWT dan MFCC, penelitian ini juga menggunakan *Shannon Entropy* sebagai fitur tambahan untuk mengukur tingkat kompleksitas dan ketidakteraturan sinyal PCG. Nilai *entropy* dihitung berdasarkan distribusi probabilitas amplitudo sinyal yang diperoleh melalui histogram dengan 100 bin. Semakin tinggi nilai *entropy*, semakin kompleks dan tidak teratur pola sinyal yang diamati. Fitur *entropy* digunakan karena mampu menangkap informasi statistik yang tidak sepenuhnya direpresentasikan oleh fitur DWT maupun MFCC.

2.6.4. Penggabungan Fitur

Fitur Yang dihasilkan dari DWT, MFCC, dan *Entropy-Based* kemudian digabungkan menggunakan metode *feature-level fusion* melalui teknik *concatenation*. Penggabungan dilakukan secara horizontal sehingga seluruh fitur hasil ekstraksi menjadi satu vektor fitur yang lebih komprehensif.

Proses ekstraksi fitur dilakukan pada data latih maupun data uji menggunakan tahapan dan parameter yang sama. pada data latih, ekstraksi fitur diterapkan setelah proses augmentasi sehingga fitur yang dihasilkan digunakan untuk melatih model klasifikasi. Sementara itu, pada data uji, ekstraksi fitur dilakukan langsung pada sinyal asli tanpa augmentasi untuk menjadi objektivitas proses evaluasi. Dengan demikian, baik data latih maupun data uji memiliki struktur fitur yang sama sebelum digunakan dalam proses klasifikasi.

2.7. Scaling

Setelah penggabungan fitur, dilakukan standarisasi data menggunakan *StandardScaler*. Standarisasi bertujuan untuk menyamakan skala fitur hasil ekstraksi DWT, MFCC, dan *Entropy-Based Features* sehingga memiliki rata-rata 0 dan standar deviasi 1. Parameter standarisasi dihitung dari data latih dan diterapkan pada data uji menggunakan parameter yang sama untuk menghindari data *leakage*. Tahap ini dilakukan agar proses klasifikasi menggunakan SVM dan Random Forest dapat berjalan lebih optimal.

2.8. Klasifikasi

2.8.1. Support Vector Machine

Pada penelitian ini klasifikasi dilakukan menggunakan SVM dengan kernel RBF, parameter $C=10$, $\gamma=scale$, dan $class_weight=balanced$. Model dilatih menggunakan data latih dan digunakan untuk memprediksi kelas pada uji. Evaluasi performa dilakukan menggunakan *accuracy*, *precision*, *f1-score*, dan *confusion matrix*.

2.8.2. Random Forest

Sebagai metode pembandingan, penelitian ini menggunakan *Random Forest* dengan 100 pohon keputusan ($n_estimator=100$) dan $random_state=42$. Model dilatih menggunakan data latih dan digunakan untuk memprediksi kelas pada data uji. Evaluasi performa dilakukan menggunakan *accuracy*, *precision*, *f1-score*, dan *confusion matrix*.


3. Hasil dan Analisis

3.1. SVM

Setelah dilakukan pengujian menggunakan algoritma *Support Vector Machine* (SVM). Berikut hasil evaluasi SVM berdasarkan metrik *accuracy*, *precision*, *recall*, *f1-score* dan *confusion matrix*.

Tabel 1. Hasil SVM

	Precision	Recall	F1-Score	Support
Normal	0.74	0.79	0.76	200
Abnormal	0.94	0.93	0.94	772
Accuracy			0.90	972
Macro Avg	0.84	0.86	0.85	972
Weighted Avg	0.90	0.90	0.90	972



Gambar 6. Confusion Matrix Random Forest

Support Vector Machine (SVM) memperoleh *accuracy* sebesar 90% dalam mengklasifikasikan sinyal PCG ke dalam kelas normal dan abnormal. Pada kelas normal, model menghasilkan *precision* sebesar 0,74, *recall* sebesar 0,79, dan *f1-score* sebesar 0,76. Hasil ini menunjukkan bahwa model mampu mengenali sebagian besar data normal dengan baik, meskipun masih terdapat beberapa data normal yang salah diklasifikasikan sebagai abnormal. Pada kelas abnormal, diperoleh *precision* sebesar 0,94, *recall* sebesar 0,93, dan *f1-score* sebesar 0,94. Nilai tersebut menunjukkan bahwa SVM memiliki kemampuan yang sangat baik dalam mendeteksi sinyal jantung abnormal. Selain itu, nilai *macro average f1-score* sebesar 0,85 dan *weighted average f1-score* sebesar 0,90 menunjukkan bahwa model memiliki performa yang baik secara keseluruhan dalam membedakan kondisi jantung normal dan abnormal.

Berdasarkan Gambar 6, SVM berhasil mengklasifikasikan 157 data normal dan 716 data abnormal dengan benar. Namun, masih terdapat 43 data normal yang salah diklasifikasikan sebagai abnormal serta 56 data abnormal yang salah diklasifikasikan sebagai normal. Jumlah prediksi benar pada kedua kelas jauh lebih besar dibandingkan jumlah kesalahan klasifikasi, sehingga menunjukkan bahwa model SVM mampu membentuk batas pemisah yang baik antara kelas normal dan abnormal berdasarkan fitur hasil ekstraksi DWT, MFCC, dan *Entropy-Based Feature*.


3.2. Random Forest

Setelah dilakukan pengujian menggunakan algoritma *Random Forest* sebagai metode pembanding. Berikut hasil evaluasi *Random Forest* berdasarkan metrik *accuracy*, *precision*, *recall*, *f1-score* dan *confusion matrix*.

Tabel 2. Hasil Random Forest

	Precision	Recall	F1-Score	Support
Normal	0,70	0,81	0,75	200
Abnormal	0,95	0,91	0,93	772
Accuracy			0,89	972

Macro Avg	0,83	0,86	0,84	972
Weighted Avg	0,90	0,89	0,89	972



Gambar 7. Confusion Matrix Random Forest

Random Forest memperoleh *accuracy* sebesar 89%, sedikit lebih rendah dibandingkan dengan SVM. Pada kelas normal, model menghasilkan *precision* 0,70, *recall* 0,81, dan *f1-score* 0,75. Nilai *recall* yang lebih tinggi dibandingkan SVM menunjukkan bahwa *Random Forest* lebih banyak mengenali data normal dengan benar. Pada kelas abnormal, diperoleh *precision* 0,95, *recall* 0,91, dan *f1-score* 0,93. Hasil ini menunjukkan bahwa *Random Forest* juga sangat baik dalam mendeteksi kelainan jantung, meskipun kemampuan deteksinya sedikit lebih rendah dibandingkan dengan SVM karena nilai *recall* dan *f1-score* kelas abnormal lebih kecil.

Berdasarkan gambar 7, *Random Forest* berhasil mengklasifikasikan 162 data normal dan 703 data abnormal dengan benar. Namun masih terdapat sekitar 38 data normal salah prediksi sebagai abnormal dan 69 data abnormal yang salah prediksi sebagai normal.

4. Kesimpulan

Penelitian ini berhasil menerapkan metode klasifikasi kelainan jantung pada sinyal *Phonocardiogram* (PCG) menggunakan kombinasi Discrete Wavelet Transform (DWT), *Mel-Frequency Cepstral Coefficients* (MFCC), dan *Entropy-Based Feature*. Sebelum proses klasifikasi, dilakukan *preprocessing* berupa *resampling*, normalisasi, *denoising*, serta penyesuaian panjang sinyal. Selain itu, ketidakseimbangan kelas pada data training diatasi menggunakan teknik data *augmentation* melalui *amplitude scaling*, *Gaussian noise injection*, dan *time shifting* sehingga distribusi data menjadi lebih seimbang.

Hasil penelitian menunjukkan bahwa kombinasi fitur DWT, MFCC, dan *Entropy-Based Feature* mampu merepresentasikan karakteristik sinyal PCG dengan baik untuk membedakan kondisi jantung normal dan abnormal. Berdasarkan hasil evaluasi, algoritma *Support Vector Machine* (SVM) memperoleh performa terbaik

dengan *accuracy* sebesar 90%, *precision* sebesar 0,94, *recall* sebesar 0,93, dan *f1-score* sebesar 0,94 pada kelas abnormal. Sementara itu, *Random Forest* memperoleh *accuracy* sebesar 89% dengan performa yang baik juga dalam mendeteksi kelainan jantung. Perbandingan kedua metode menunjukkan bahwa SVM lebih unggul dibandingkan *Random Forest* pada dataset yang digunakan. Oleh karena itu, kombinasi data *augmentation*, ekstraksi fitur DWT, MFCC, *Entropy-Based*, dan algoritma SVM dapat menjadi pendekatan yang efektif untuk klasifikasi kelainan jantung berbasis sinyal *Phonocardiogram* (PCG).

5. Daftar Pustaka

- Abdusyukur, F. (2023). PENERAPAN ALGORITMA SUPPORT VECTOR MACHINE (SVM) UNTUK KLASIFIKASI PENCEMARAN NAMA BAIK DI MEDIA SOSIAL TWITTER. *Komputa: Jurnal Ilmiah Komputer Dan Informatika*, 12(1), 73–82. <https://doi.org/10.34010/KOMPUTA.V12I1.9418>
- Alegh, N., Thottoli, M., Mian, N., Longstaff, A., & Fletcher, S. (2021). Feature Extraction of Time-Series Data Using DWT and FFT for Ballscrew Condition Monitoring. *Advances in Transdisciplinary Engineering*, 15, 402–407. <https://doi.org/10.3233/ATDE210069>
- Bej, S., Davtyan, N., Wolfien, M., Nassar, M., & Wolkenhauer, O. (2020). LoRAS: an oversampling approach for imbalanced datasets. *Machine Learning 2020* 110:2, 110(2), 279–301. <https://doi.org/10.1007/S10994-020-05913-4>
- Bej, S., Davtyan, N., Wolfien, M., Nassar, M., & Wolkenhauer, O. (2020). LoRAS: an oversampling approach for imbalanced datasets. *Machine Learning 2020* 110:2, 110(2), 279–301. <https://doi.org/10.1007/S10994-020-05913-4>
- CICILYA, O. T. (2024). KLASIFIKASI IRAMA JANTUNG NORMAL DAN ABNORMAL PADA CITRA SINYAL EKG MENGGUNAKAN METODE CNN DI RUMAH SAKIT UMUM DAERAH DOK II JAYAPURA.
- Li, J., Ke, L., & Du, Q. (2019). Classification of Heart Sounds Based on the Wavelet Fractal and Twin Support Vector Machine. *Entropy* 2019, Vol. 21, Page 472, 21(5), 472. <https://doi.org/10.3390/E21050472>
- Rismawati, P., Natalisanto, A. I., Perwitasari, D. R., & Putri, S. (2024). Klasifikasi Sel Tumor Payudara Menggunakan Algoritma Support Vector Machine (SVM). *Progressive Physics Journal*, 5(1), 356–361. <https://doi.org/10.30872/PPJ.V5I1.1092>

- Touluni, Y., Nsiri, B., & Drissi, T. B. (2023). ECG Signal Classification Using DWT, MFCC and SVM Classifier. *Traitement Du Signal*, 40(1), 335–342. <https://doi.org/10.18280/TS.400133>
- Utari, D. T. (2023). INTEGRATION OF SVM AND SMOTE-NC FOR CLASSIFICATION OF HEART FAILURE PATIENTS. *BAREKENG: Jurnal Ilmu Matematika Dan Terapan*, 17(4), 2263–2272. <https://doi.org/10.30598/BAREKENGVOL17ISS4PP2263-2272>
- Wulandari, N., & Islam Sultan Agung, U. (2025). IMPLEMENTASI TEKNIK RESAMPLING UNTUK MENGATASI KETIDAKSEIMBANGAN DATA TERHADAP KLASIFIKASI ANEMIA MENGGUNAKAN SUPPORT VECTOR MACHINE. *Jurnal Rekayasa Sistem Informasi Dan Teknologi*, 2(3), 942–951. <https://doi.org/10.70248/JRSIT.V2I3.1856>
- Aurelius, R., Diaz, N., Luh, N., Suwirmayanti, G. P., Budiarta, K., Studi, P., & Komputer, S. (2024). *PERBANDINGAN KUALITAS PENGENALAN SUARA UNTUK EKSTRAKSI FITUR MENGGUNAKAN MFCC DAN SPECTRAL*. 06.
- Chashmi, A. J., & Amirani, M. C. (2019). An efficient and automatic ECG arrhythmia diagnosis system using DWT and HOS features and entropy-based feature selection procedure. *Journal of Electrical Bioimpedance*, 10(1), 47–54. <https://doi.org/10.2478/joeb-2019-0007>
- Malik, A., Mandala, S., & Pramudyo, M. (2023). Study of Feature Extraction Method to Detect Myocardial Infraction Using a Phonocardiogram. *JURNAL MEDIA INFORMATIKA BUDIDARMA*, 7(3), 1238–1246. <https://doi.org/10.30865/MIB.V7I3.6442>
- Shakhovska, N., & Zagorodniy, I. (2024). Classification of Acoustic Tones and Cardiac Murmurs Based on Digital Signal Analysis Leveraging Machine Learning Methods. *Computation* 2024, Vol. 12, Page 208, 12(10), 208. <https://doi.org/10.3390/COMPUTATION12100208>

6. Kontribusi Kelompok

Nama Anggota	Kontribusi	Url Github
Aisyah Imani Khoirunnisa (24031554020)	Menyusun code augmentasi, Entropy-Based Feature, dan Random Forest. Menyusun laporan bagian rumusan	URL Github Aisyah

masalah, pendekatan pemecahan masalah, eksplorasi dataset, tinjauan pustaka SVM, Entropy-Based Feature, EDA, penjelasan klasifikasi, augmentasi, hasil analisis Random Forest dan kesimpulan.

Aryanti Indah
Lestari
(24031554196)

Menyusun code [URL](#) [Github](#)
preprocessing, EDA, DWT, [Aryanti](#)
dan SVM.
Menyusun laporan bagian latar belakang, alur penelitian, tinjauan pustaka DWT, MFCC, Random Forest, penjelasan preprocessing, ekstraksi fitur, scaling dan hasil analisis SVM.
